

Scry 软件性能（核心指标）测试报告

Scry 安全智能运维平台

文档版本：1.0.0

产品版本：Scry 1.0.0

对应赛题：第十五届中国软件杯 A2“面向麒麟操作系统的安全智能运维 Agent 设计与实现”

测试日期：2026-07-20

报告范围：开发环境 HTTP、安全规则、资源和算法质量基准

测试与验证环境说明：已在麒麟高级服务器操作系统 V11 + 龙芯（LoongArch）平台完成软件适应性测试，确保 Scry 可以在该环境下完美运行。考虑到麒麟-龙芯实体环境的持续使用成本，除适应性测试外，现阶段其他功能与性能测试主要在 macOS 开发环境及其中运行的麒麟系统虚拟机中开展；后续将在麒麟-龙芯平台补充相应测试。

1. 测试目标

本报告验证与赛题直接相关的核心指标：

- 1. Agent 基础服务在并发请求下的响应时间、失败率和吞吐。
- 2. Prompt Injection、意图分类和命令风险分析的本地计算延迟。
- 3. Agent、Query Service、ClickHouse 和 PostgreSQL 的开发环境资源占用快照。
- 4. TopoMem 运行记忆检索和根因定位的算法质量指标。
- 5. 麒麟发布包体积和可交付性。

软件已在麒麟 V11 + 龙芯（LoongArch）平台完成适应性测试并确认可完美运行。受实体平台持续使用成本影响，本报告中的其他性能数据主要来自 macOS 开发环境及其中运行的麒麟系统虚拟机；后续将在麒麟-龙芯平台补充测试。

2. 指标与门槛

ID	指标	验收门槛	依据
PI-API-001	Agent 健康端点，20 并发 200 请求失败数	0	比赛验收计划
PI-SEC-001	本地安全裁决规则计算 P95	< 50 ms	产品非功能需求
PI-REL-001	并发请求失败率	0%	可靠性要求
PI-RCA-001	TopoMem Root Hit@5	越高越好，至少优于平面检索基线	智能根因分析核心指标
PI-PKG-001	发布包	不打包第三方依赖目录，体积可提交	赛题提交要求

3. 测试环境

项目	配置
主机	Apple M4，16 GB 内存
操作系统	macOS 26.5.2， Darwin ARM64
麒麟-龙芯适配平台	麒麟高级服务器操作系统 V11 + 龙芯（LoongArch），软件适应性测试通过

项目	配置
开发期麒麟环境	macOS 中运行的麒麟系统虚拟机
Node.js	v24.18.0
Docker	Server 29.4.0, Compose v5.1.2
服务形态	Docker Compose 开发栈
Agent Service	healthy, 127.0.0.1:4111
Query Service	healthy, 127.0.0.1:8080
Web Console	healthy, 127.0.0.1:3301
数据服务	PostgreSQL、ClickHouse、OpenTelemetry Collector

测试期间主机上存在其他开发进程，结果用于功能容量基线，不等同于独占压测环境。

4. 测试工具与方法

4.1 HTTP 并发

使用仓库脚本：

```
SCRY_LOAD_REQUESTS=<请求数> \  
SCRY_LOAD_CONCURRENCY=<并发数> \  
node tests/performance/agent-api-load.mjs
```

未设置 SCRY_TEST_TOKEN 时脚本请求 /health，记录失败数和 P50/P95/P99。最高负载场景使用 /usr/bin/time -p 记录包含 Node 进程启动与退出在内的总墙钟时间，因此吞吐估算偏保守。

4.2 安全规则微基准

使用构建后的规则模块，在单进程内循环 50,000 次：

- Prompt Injection 检测 + 意图分类：混合普通诊断、指令覆盖、服务重启和秘密读取样本。
- 命令风险分析：混合固定包装器、sudo -n 包装器、rm -rf、Shell 和管道样本。

微基准只衡量规则计算，不包含审计数据库写入、网络、审批或 SSH 执行。

4.3 资源占用

使用 docker stats --no-stream 获取单次快照。该指标受容器运行时缓存、历史运行时长和同机负载影响，只用于容量规划参考。

4.4 算法质量

TopoMem 指标来自项目随附研究材料 `main.pdf` 的受控评测：55 个独立故障、548 份运维文档，并包含 24 个固定 Agent 配置的下游诊断实验。该数据用于说明根因记忆检索质量，不是本轮 HTTP 压测结果。

5. HTTP 并发测试结果

场景	请求数	并发	失败	失败率	P50	P95	P99
L1	200	20	0	0%	24.51 ms	90.66 ms	205.51 ms
L2	1,000	50	0	0%	12.45 ms	74.24 ms	184.57 ms
L3	5,000	100	0	0%	11.10 ms	22.88 ms	54.60 ms

L3 总墙钟时间为 0.94 s，保守吞吐估算为：

$$5000 / 0.94 = 5319 \text{ requests/s}$$

5.1 结果分析

- 三个并发级别均为零失败，满足 PI-REL-001。
- 20 并发 200 请求零失败，满足 PI-API-001。
- L1/L2 的尾延迟高于 L3，与首次连接、JIT、容器调度和短样本分位数波动有关。
- `/health` 数据用于衡量 Agent 基础 HTTP 服务与运行时响应，不包含外部模型生成时间。

6. 安全规则性能结果

6.1 Prompt Injection + 意图分类

迭代	P50	P95	P99	最大值
50,000	0.0005 ms	0.0016 ms	0.0040 ms	3.1320 ms

6.2 命令风险分析

迭代	拒绝样本	P50	P95	P99	最大值
50,000	30,000	0.0007 ms	0.0021 ms	0.0061 ms	4.5257 ms

6.3 结果分析

- 两条纯规则路径 P95 均远低于 50 ms，PI-SEC-001 在“规则计算、不含审计持久化”范围内通过。

- 极小数值接近高精度计时器和循环开销，适合证明规则计算不会成为主要瓶颈，不适合推导跨硬件的精确微秒差异。

7. 服务资源占用快照

容器	CPU 快照	内存占用
Agent Service	0.07%	416.2 MiB
Query Service	0.00%	121.5 MiB
ClickHouse	5.76%	1.091 GiB
PostgreSQL	0.00%	32.04 MiB

补充观察：OpenTelemetry Collector 约 114.6 MiB，Alertmanager 约 13.5 MiB。Frontend 开发容器因 TypeScript/开发构建进程可超过 2 GiB，不代表 Nginx 静态生产部署。

资源数据表明 Agent Service 的常驻内存明显低于 ClickHouse 数据面，主要资源消耗集中在遥测数据存储与开发期前端构建进程。

8. TopoMem 全量评测数据

本节完整整理根目录 `main.pdf` 中 TopoMem 的量化数据。TopoMem 使用当前故障的运行时 Trace 作为导航结构：先沿异常调用链定位候选根服务，再使用日志字段、Span 标签、状态码和告警词项形成错误签名，对候选服务内的运维记忆进行重排。TopoMem-MP 最多保留三条异常路径，用于处理冲突 Trace。

8.1 数据集与实验配置

项目	数据
主评测故障	55 个独立故障，每条路径包含 3-4 个服务
运维文档	548 份，约 165,000 词
故障-文档组合	30,140 对
文档类型	Runbook、Postmortem、服务画像、变更记录、值班交接和 Agent 记忆
查询复制检查	没有文档包含其查询的完整拷贝
错误签名词项覆盖	全部文档 29.9%，根因文档 38.2%
完整签名泄露	没有根因文档包含完整错误签名
服务名泄露	查询和签名均省略终点服务名
文档分块	按段落切分，单块最大 1,800 字符

项目	数据
标注核验	3 个 LLM 标注者；36 个角色标签案例全体一致；84 份无元数据文档通过多数票确定服务标签
随机实验	每个随机条件 20 个固定种子实现
置信区间	10,000 次故障级 Bootstrap，报告配对 95% CI
Trace 压力集	18 条路径用于多路径参数校准，37 条路径留出评测
异常边阈值	错误率 0.10
Trace Walk 最大深度	5
TopoMem-MP 路径数	最多 3 条异常路径

公开事故报告的词汇差异分析覆盖 5 个公开 Postmortem 索引中的 99 组“症状-根因”段落。高 IDF 词项定义为样本中 IDF 最高的 70%；49.5% 的段落对没有共享高 IDF 词项，中位共享量仅为 1 个词，说明跨服务词汇鸿沟在公开事故资料中同样普遍存在。

8.2 指标定义

- Root Hit@5: 前 5 条结果中至少出现 1 份根因文档的故障比例。
- MRR@5: 首份根因文档在前 5 条中的平均倒数排名；未命中记为 0。
- Role Coverage@5: 前 5 条结果对 surface、bridge、root cause、remediation 四类角色的平均覆盖比例。
- Gold docs@5: 前 5 条证据中金标准文档的平均数量。
- Root/Mode Score: 根因服务和故障模式得分，范围均为 0-2。

8.3 根因文档检索结果（Table I）

方法	Root Hit@5	95% CI	MRR@5
BM25	0.636	[0.509, 0.764]	0.222
Dense (Qwen3-Embedding-0.6B)	0.600	[0.473, 0.727]	0.212
BM25 + signature	0.745	[0.618, 0.855]	0.296
Dense + signature	0.636	[0.509, 0.764]	0.258
ApeRAG: alert only	0.200	[0.109, 0.309]	0.043
ApeRAG: trace text	0.218	[0.109, 0.327]	0.048
ApeRAG: trace + signature text	0.309	[0.182, 0.436]	0.078
TopoMem-Walk (trace + dense)	0.927	[0.855, 0.982]	0.515
TopoMem (trace + signature + dense)	0.964	[0.909, 1.000]	0.655

完整 TopoMem 在 55 个故障中命中 53 个，TopoMem-Walk 命中 51 个，BM25 + signature 命中 41 个，BM25 命中 35 个，Dense 命中 33 个。相较 BM25，TopoMem 的 Hit@5 提升 0.327，95% CI 为 [0.200, 0.455]。相较 TopoMem-Walk，TopoMem 的配对 Hit@5 差值为 0.036，95% CI 为 [-0.055, 0.127]；MRR@5 差值为 0.140，95% CI 为 [0.062, 0.223]。

ApeRAG 从 alert only 的 0.200 提升到 trace text 的 0.218，再提升到 trace + signature text 的 0.309；将相同路径真正作为导航约束执行时，TopoMem-Walk 达到 0.927。

8.4 错误签名质量敏感性 (Table II)

签名条件	Root Hit@5	MRR@5	Role Coverage@5
Observed signature	0.964	0.655	0.741
Retain 50%	0.965	0.609	0.729
50% + equal-length foreign noise	0.966	0.600	0.720
Query only (TopoMem-Walk)	0.927	0.515	0.727

保留 50% 签名时，相对 TopoMem-Walk 的 MRR@5 优势为 +0.094，95% CI 为 [0.040, 0.150]；加入等长外来噪声时优势为 +0.085，95% CI 为 [0.030, 0.142]。结果表明 Trace 决定候选区域，签名质量主要影响根因文档在候选区域中的排序。

8.5 Trace 观测压力与多路径路由 (Table III)

该实验在 37 条留出路径、548 份文档和每个条件 20 个固定种子实现上进行。

Trace 观测条件	BM25 + signature	TopoMem	TopoMem-MP
Clean finite-count trace	0.730	0.946	0.946
Head sampling 20%	0.730	0.926	0.928
Edge dropout 10%	0.730	0.853	0.878
Edge dropout 30%	0.730	0.685	0.773
Five-call low traffic	0.730	0.854	0.900
Stale high-error branch	0.730	0.001	0.919
Concurrent fault branch	0.730	0.053	0.919

在 30% 边丢失时，TopoMem-MP 相对 TopoMem 提升 0.088，95% CI 为 [0.016, 0.161]；五调用低流量条件提升 0.046，95% CI 为 [0.022, 0.072]。陈旧高错误分支提升 0.918，95% CI 为 [0.811, 0.999]；并发故障分支提升 0.866，95% CI 为 [0.772, 0.942]，且干净 Trace 的 Hit@5 保持不变。

其他观测扰动相对于干净条件的变化为：错误偏置尾采样 -0.016，95% CI [-0.049, 0.000]；重试膨胀 -0.014，95% CI [-0.041, 0.000]；5% 错误标签噪声 -0.011，95% CI [-0.032, 0.000]。

TopoMem-MP 在冲突分支下对签名质量的结果为：保留 50% 签名时，陈旧/并发分支 Hit@5 为 0.822；加入等长外来噪声时为 0.707；无签名时回退到 query-only BM25，Hit@5 为 0.595。

8.6 检索延迟

检索延迟在 Apple M4 Mac mini、16 GB 内存环境测得，包含 CPU 查询向量计算，但不包含一次性的模型装载时间。

方法	P50	P95	P99	其他耗时
TopoMem-Walk	164 ms	248 ms	357 ms	模型首次装载 4.9 s，不计入分位数
TopoMem	167 ms	251 ms	360 ms	模型首次装载 4.9 s，不计入分位数
ApeRAG: trace text	3,793 ms	6,945 ms	9,200 ms	索引构建 4,144.8 s

ApeRAG 在 trace + signature 条件下的 P50 为 3,907 ms。TopoMem 的亚秒级路径适合位于告警进入与 Agent 首次诊断动作之间的同步检索阶段；TopoMem-Walk 与完整 TopoMem 的延迟差异很小，签名重排没有引入明显的额外开销。

8.7 下游 Agent 诊断结果 (Table IV)

下游实验覆盖 24 个多跳故障，由 6 个故障族、每族 4 个故障模式构成，使用 312 份运维文档。Agent 固定为 GLM-5.1、temperature 0.2，最多调用 `get_logs`、`get_metrics` 和 `query_service` 三次，最多访问两个服务。

指标	No context	BM25	Dense	TopoMem
Gold docs@5	0.00	0.04	0.00	2.33
Initial root	0.12	0.17	0.00	0.58
Final root	2.00	1.83	1.88	2.00
Final mode	1.75	1.33	1.67	2.00
Wrong first target	0.46	0.54	0.38	0.08
Root in <=2 calls	0.67	0.46	0.83	1.00

各条件实际使用的工具预算接近一致，平均为 2.9-3.0 次调用。TopoMem 将错误首个工具目标率从 BM25 的 0.54 降至 0.08，使全部故障在两次工具调用内到达根服务，并将最终故障模式得分提高到 2.00。

8.8 TopoMem 数据结论

TopoMem 的主要收益来自 Trace-guided Walk 对根服务区域的定位：Root Hit@5 从 BM25 的 0.636 提升到 0.927；错误签名重排进一步将完整方法提高到 0.964，并使 MRR@5 增加 0.140。TopoMem-MP 在陈旧分支和并发故障分支上均达到 0.919，同时保持干净 Trace 的 0.946。下游 Agent 的错误首目标率降至 0.08，两次调用内根服务到达率为 1.00。

9. 发布包指标

当前发布产物：

文件	大小	说明
scry-1.0.0-kylin-v11-loong64.tar.gz	约 8.0 MiB	源码、锁文件、部署脚本、配置和文档 PDF
SHA-256 文件	约 4 KiB	用于传输完整性校验

打包脚本排除 `node_modules`、构建缓存、测试、样例测试数据、本地数据库、Git 历史和第三方依赖目录，符合赛题“依赖应在安装时从软件源下载”的要求。

10. 测试结论

Scry 已通过麒麟 V11 + 龙芯（LoongArch）平台软件适应性测试，确认软件能够在该环境下完美运行。

在当前开发环境中，Scry Agent 健康端点在 20/50/100 并发下均为零失败；最高场景 5,000 请求的 P95 为 22.88 ms，保守吞吐约 5,319 req/s。本地 Prompt Injection/意图分类和命令风险规则 P95 均远低于 50 ms。Agent Service 资源快照约 416.2 MiB，包含提交文档 PDF 的精简麒麟发布包约 8.0 MiB。

TopoMem 受控评测显示完整方法 Root Hit@5 为 0.964、MRR@5 为 0.655；TopoMem-MP 在陈旧和并发冲突分支上均达到 0.919；下游诊断错误首个工具目标率降至 0.08，两次工具调用内到达根服务的比例达到 1.00，体现了针对赛题根因分析和自然语言准确性的核心优势。

PI-API-001、PI-REL-001、PI-SEC-001、PI-RCA-001 和 PI-PKG-001 均达到本报告规定的验收标准。